

X5I0050 - Langages et automates

Généralités sur les langages

D. Béchet & T. Sadiki

Université de Nantes & Université Internationale de Rabat

10 septembre 2014

Introduction

Langage naturel, langage mathématique, langage de programmation (C, Java, ...), langage formel, format de fichiers, normalisation, ...

Langage formel : un vocabulaire + des règles de grammaires

Théorie des langages formels

- **Analyse** : déterminer si une phrase appartient ou non au langage.
- **Génération** : générer l'ensemble des phrases (mots) d'un langage

Syntaxe uniquement

Sémantique non prise en compte

Voir Noam CHOMSKY (sur Wikipédia) pour l'aspect historique

Plan Chapitre 1

- 1 Notions de monoïde
- 2 Mots et monoïdes
- 3 Relations entre mots
- 4 Langages et opérations

Définition de monoïde

Définition 1.1 - Monoïde

Un **monoïde** est un ensemble E muni d'une opération binaire interne associative \oplus et possédant un élément neutre ε

Notation : $\langle E, \oplus, \varepsilon \rangle$

Exemples :

- $\langle \mathbb{N}, +, 0 \rangle$ les entiers positifs ou nuls avec l'addition (élément neutre 0)
- $\langle \mathbb{Z}, +, 0 \rangle$ les entiers relatifs avec l'addition (élément neutre 0)
- $\langle \mathbb{R}, \times, 1 \rangle$ les nombres réels avec la multiplication (élément neutre 1)
- $\langle \mathcal{P}(U), \cup, \emptyset \rangle$ les sous-ensembles d'un univers U avec l'union
- etc

Propriétés d'un monoïde $\langle E, \oplus, \varepsilon \rangle$

- \oplus est une **opération binaire interne** (ou **stable**) à E :

$$\forall x, y \in E, x \oplus y \text{ est défini et } x \oplus y \in E$$

- \oplus est **associative** :

$$\forall x, y, z \in E, (x \oplus y) \oplus z = x \oplus (y \oplus z)$$

Pour cette raison, les parenthèses sont souvent omises

- ε est un **élément neutre** de E pour \oplus :

$$\varepsilon \in E \text{ et } \forall x \in E, \varepsilon \oplus x = x \oplus \varepsilon = x$$

- Il ne peut exister qu'un seul élément neutre dans un monoïde : si ε et ε' sont deux éléments neutres de E pour \oplus , alors $\varepsilon = \varepsilon \oplus \varepsilon' = \varepsilon'$

Définition de sous-monoïde

Définition 1.2 - Sous-monoïde

Soit $\langle E, \oplus, \varepsilon \rangle$, un monoïde et T un sous-ensemble de E ($T \subseteq E$).
 $\langle T, \oplus, \varepsilon \rangle$ est un **sous-monoïde** de $\langle E, \oplus, \varepsilon \rangle$, ssi c'est un monoïde.
 Puisque $\langle E, \oplus, \varepsilon \rangle$ est un monoïde, il suffit de démontrer que :

- $\varepsilon \in T$
- \oplus est stable dans T : $\forall t, t' \in T, t \oplus t' \in T$

Définition 1.3 - Monoïde engendré

Soit $M = \langle E, \oplus, \varepsilon \rangle$ un monoïde. Pour toute partie A de E , on peut définir le plus petit sous-monoïde de M contenant A . On l'appelle le **sous-monoïde de M engendré par A** .

Exercices sur les monoïdes

Monoïde ? Sous-monoïde ? Monoïde engendré ?

\mathbb{N} est l'ensemble des entiers naturels

$Pair(\mathbb{N})$ est l'ensemble des entiers pairs (ou nuls)

$Impair(\mathbb{N})$ est l'ensemble des entiers impairs

$$\langle \mathbb{N}, +, 0 \rangle ?$$

$$\langle \mathbb{N}, \times, 1 \rangle ?$$

$$\langle Pair(\mathbb{N}), +, 0 \rangle ?$$

$$\langle Pair(\mathbb{N}), \times, 1 \rangle ?$$

$$\langle Impair(\mathbb{N}), +, 0 \rangle ?$$

$$\langle Impair(\mathbb{N}), \times, 1 \rangle ?$$

Exercices sur les monoïdes - Quelques réponses

Monoïde ? Sous-monoïde ? Monoïde engendré ?

- ① $\langle \text{Pair}(\mathbb{N}), +, 0 \rangle$: un monoïde
- ② $\langle \text{Pair}(\mathbb{N}), +, 0 \rangle$: sous-monoïde de $\langle \mathbb{N}, +, 0 \rangle$
- ③ $\langle \text{Pair}(\mathbb{N}), +, 0 \rangle$: le sous-monoïde de $\langle \mathbb{N}, +, 0 \rangle$ engendré par $\{2\}$
- ④ $\langle \text{Impair}(\mathbb{N}), +, 0 \rangle$: n'est pas un monoïde

Démonstrations :

- (3) implique (2) qui implique (1)
- (3) se démontre en remarquant que 2 est pair, en montrant (2) puis en montrant par une **récurrence simple** que tout sous-monoïde de $\langle \mathbb{N}, +, 0 \rangle$ contenant l'entier 2 doit contenir au moins tous les entiers pairs
- (4) se démontre facilement en remarquant que la somme de deux nombres impairs n'est pas impair, par exemple $1 + 1 = 2$

Définitions de symbole, alphabet, mot

Définition 1.4 - Symbole

Un **symbole** est une brique élémentaire, un atome

Définition 1.5 - Alphabet

Un **alphabet** A est un ensemble fini et non vide de symboles

Définition 1.6 - Mot

Un **mot** (**chaîne**) sur un alphabet A est une suite finie de symboles de A
Si a_1, \dots, a_n sont des symboles de A , on note $\mathbf{a_1 \cdots a_n}$ le mot qui forme la suite de ces n symboles^a

^a n peut être nul et les symboles ne sont pas forcément distincts deux à deux

Longueur d'un mot, mot vide

Définition 1.7 - Longueur d'un mot

La **longueur** d'un mot est le nombre de symboles du mot. Soit un mot w , sa longueur est notée $|w|$

Définition 1.8 - Mot vide

Le **mot vide** est le mot de longueur 0, c'est-à-dire ne contenant aucun symbole. Plutôt que de le marquer par une chaîne vide, il est souvent noté ϵ . $|\epsilon| = 0$

Définition 1.9 - Mot de longueur n , A^n , A^* et A^+

Soit A un alphabet, l'ensemble des **mots de longueur n** est noté A^n

On appelle A^* , l'ensemble de tous les mots de longueur finie construits avec les symboles de A .

On appelle A^+ , l'ensemble de tous les mots de longueur finie et non nulle construits avec les symboles de A

Concaténation

Définition 1.10 - Concaténation

Soit $v, w \in A^*$, $|v| = m$, $|w| = n$, la **concaténation** de v et w , notée $\mathbf{v \cdot w}$, est le mot de longueur $m + n$ dont les m premiers symboles sont le mot v et les n suivants le mot w . Ainsi, si $v = a_1 a_2 \dots a_m$ et $w = b_1 b_2 \dots b_n$ alors $\mathbf{v \cdot w = a_1 a_2 \dots a_m b_1 b_2 \dots b_n}$

Propriétés de la concaténation

- **associativité**, $\forall u, v, w \in A^*$, $(u \cdot v) \cdot w = u \cdot (v \cdot w) = u \cdot v \cdot w$
- généralement **non commutatif**, soit $u, v \in A^*$, $u \cdot v \neq v \cdot u$
- **élément neutre** ε , $\forall u \in A^*$, $\varepsilon \cdot u = u \cdot \varepsilon = u$

$\langle A^*, \cdot, \varepsilon \rangle$ est un **monoïde**, appelé **monoïde libre engendré par A**

Décomposition

Théorème 1.1 - Propriété de la décomposition

Tout mot v (de longueur $n = |v|$) sur un alphabet A se décompose de façon unique en $a_1 \cdot a_2 \cdot \dots \cdot a_n$, où $\forall i \in \{1 \dots n\}, a_i \in A$.

Cela signifie que le monoïde libre engendré par A est un monoïde libre au sens de l'[algèbre universelle](#), que les symboles sont [atomiques](#) et que tout mot est produit unique de concaténation des symboles qui le composent

Théorème 1.2 - Lemme de Levi

Soient $t, u, v, w \in A^*$, si $t \cdot u = v \cdot w$ alors il existe un unique $(\exists!) z \in A^*$ tel que :

- ① $(v = t \cdot z \text{ et } u = z \cdot w)$
- ② ou bien $(t = v \cdot z \text{ et } z \cdot u = w)$

Ce lemme est un résultat intermédiaire utile dans les démonstrations

Démonstration du lemme de Levi

De manière informelle, si l'on a $t \cdot u = v \cdot w$, il y a trois cas :

- ① $|t| = |v|$ et $|u| = |w|$: $\begin{array}{c} \text{ttttttuuuuuu} \\ | \\ \text{vvvvvvwwwww} \end{array} \implies z = \varepsilon$
- ② $|t| < |v|$ et $|u| > |w|$: $\begin{array}{c} \text{ttttuuuuuuuu} \\ | \text{zzzz} | \\ \text{vvvvvvvvwwww} \end{array}$
- ③ $|t| > |v|$ et $|u| < |w|$: $\begin{array}{c} \text{ttttttttuuuu} \\ | \text{zzzz} | \\ \text{vvvvwwwwwww} \end{array}$

Puissance

Notation - Puissance

La **puissance** n du mot x (notée x^n) est le mot $v = x \cdot \dots \cdot x$ (n fois).

On a $|v| = n \times |x|$

$$\forall x \in A^*, x^0 = \varepsilon, x^1 = x$$

$$\forall x \in A^*, x^n = \varepsilon \implies x = \varepsilon \text{ ou } n = 0$$

Exercices sur les mots

- ① Donner la longueur des mots suivants sur l'alphabet a, b, c :

$abcb$

$abba$

ε

bb

- ② Donner la longueur des mots suivants sur l'alphabet $a, b, c, ', ' :'$:

$a, bbaa$

$achbbaa$

- ③ Soient a, b des symboles de A et u un mot de A^* . Montrer que si $u \cdot a = b \cdot u$ alors $a = b$ et $u \in \{a\}^*$.

Exercices sur les mots - Réponses

- ① Donner la longueur des mots suivants sur l'alphabet a, b, c :

$$abcb \Rightarrow 4$$

$$abba \Rightarrow 4$$

$$\varepsilon \Rightarrow 0$$

$$bb \Rightarrow 2$$

- ② Donner la longueur des mots suivants sur l'alphabet $a, b, ch, ', ' :$

$$a, bbaa \Rightarrow 6$$

$$achbbaa \Rightarrow 6$$

- ③ Soient a, b des symboles de A et u un mot de A^* . Montrer que si $u \cdot a = b \cdot u$ alors $a = b$ et $u \in \{a\}^*$

Démonstration : par induction généralisée sur la longueur de u et en utilisant le lemme de Levi

Exercices sur les mots - Démonstration de (3)

- **Hypothèse d'induction** Soient $k \in \mathbb{N}$, $u \in A^*$, $a, b \in A$ avec $|u| = k$, nous supposons que la propriété est vraie pour tout mot u' de longueur plus petite (strictement) que k .
- **Hypothèse** : nous supposons que $u \cdot a = b \cdot u$
- **Utilisation du lemme de Levi** : nous avons soit $u = b \cdot z$ et $z \cdot a = u$ soit $b = u \cdot z$ et $z \cdot u = a$
- **Sous cas 1** : si $k = 0$ alors $u = \varepsilon$ donc $a = b$ et $u \in \{a\}^*$
- **Sous cas 2** : si $k > 0$, $b = u \cdot z$ et $z \cdot u = a$ alors $z = \varepsilon$ et $a = b = u$ donc $a = b$ et $u \in \{a\}^*$
- **Sous cas 3** : si $k > 0$, $u = b \cdot z$ et $z \cdot a = u$ alors $z \cdot a = b \cdot z$
Utilisation de l'hypothèse d'induction : comme $z \cdot a = b \cdot z$ et $|z| < |u| = k$, nous avons $a = b$ et $z \in \{a\}^*$
 Finalement $a = b$ et $u = z \cdot a \in \{a\}^*$

Définitions de préfixe, suffixe, sous-chaîne/facteur

Définition 1.11 - Préfixe/préfixe propre

v est un **préfixe** de w ($v \in \text{Pref}(w)$) ssi $\exists z \in A^*$ tel que $w = v \cdot z$

v est un **préfixe propre** de w ($v \in \text{PrefProp}(w)$) ssi $\exists z \in A^+$ tel que $w = v \cdot z$

Définition 1.12 - Suffixe/suffixe propre

v est un **suffixe** de w ($v \in \text{Suff}(w)$) ssi $\exists z \in A^*$ tel que $w = z \cdot v$

v est un **suffixe propre** de w ($v \in \text{SuffProp}(w)$) ssi $\exists z \in A^+$ tel que $w = z \cdot v$

Définition 1.13 - Sous-chaîne

v est une **sous-chaîne** ou **facteur** de w ssi $\exists u_1, u_2 \in A^*$ tel que $w = u_1 \cdot v \cdot u_2$

facteur gauche = préfixe

facteur droit = suffixe

Occurrence et relations d'ordre sur les chaînes

Définition 1.14 - Occurrence

Une **occurrence** du symbole x dans le mot w est un entier $i > 0$ tel que le i -ème symbole de w (noté $w(i)$) est x

Le nombre d'occurrences de la lettre x dans le mot w est noté $|w|_x$

L'alphabet $A = \{x_1, x_2, \dots, x_n\}$ muni d'un ordre total $<$ sur les symboles définit sur A^* plusieurs relations d'ordre :

- l'**ordre préfixiel**, noté $<_p$: **ordre partiel** défini par : $u <_p v$ ssi u est un **préfixe propre** de v
- l'**ordre lexicographique** (ordre du dictionnaire), noté $<_L$: **ordre total** défini par : $u <_L v$ ssi u est un **préfixe propre** de v ($u <_p v$) ou bien $u = w \cdot a \cdot u_2$ et $v = w \cdot b \cdot v_2$ tels que $w \in A^*$, $a < b$ avec $a, b \in A$
- l'ordre **hiérarchique**, noté $<_h$: **ordre total** pour lequel les mots sont classés en premier lieu par **longueur**, puis pour les mots de même longueur, par **ordre lexicographique**.

Exercices sur les relations entre mots

- ❶ Soit $x = abbcc$ un mot sur l'alphabet $A = \{a, b, c\}$, donner $Pref(x)$ et $Suff(x)$.
- ❷ Soient $u_1, u_2, v \in A^*$, montrer que si $u_1 \in Pref(v)$ et $u_2 \in Pref(v)$ alors soit $u_1 \in Pref(u_2)$, soit $u_2 \in Pref(u_1)$
- ❸ Soient les mots suivants sur l'alphabet $A = \{a, b, c, d\}$ muni de l'ordre total $a < b < c < d$:
 - ❶ a
 - ❷ abcd
 - ❸ bc
 - ❹ dbc
 - ❺ ab
 - ❻ cd
 - ❼ cdab
 - ❽ abdd

Trier ces mots selon les ordres préfixiels, lexicographiques et hiérarchiques.

Exercices sur les relations entre mots - Réponses

- ① Soit $x = abbcc$ un mot sur l'alphabet $A = \{a, b, c\}$
 $Pref(x) = \{a, ab, abb, abbc, abbcc\}$
 $Suff(x) = \{c, cc, bcc, bbcc, abbcc\}$
- ② Soient $u_1, u_2, v \in A^*$, montrer que si $u_1 \in Pref(v)$ et $u_2 \in Pref(v)$ alors soit $u_1 \in Pref(u_2)$, soit $u_2 \in Pref(u_1)$

Démonstration : assez simple en utilisant le lemme de Levi

Si $u_1 \in Pref(v)$ et $u_2 \in Pref(v)$ alors $\exists w_1, w_2 \in A^*$ tels que $v = u_1 \cdot w_1 = u_2 \cdot w_2$. Le **lemme de Levi** implique que $\exists ! z \in A^*$ tel que $(u_1 = u_2 \cdot z \text{ et } w_2 = z \cdot w_1)$ ou $(u_2 = u_1 \cdot z \text{ et } w_1 = z \cdot w_2)$
 $\Rightarrow u_1 = u_2 \cdot z \text{ ou } u_2 = u_1 \cdot z \Rightarrow u_1 \in Pref(u_2) \text{ ou } u_2 \in Pref(u_1)$

Exercices sur les relations entre mots - Réponses

③ Soient les mots suivants sur l'alphabet $A = \{a, b, c, d\}$ muni de l'ordre total $a < b < c < d$:

- Ordre préfixiel :

$a <_p abcd$, $a <_p ab$, $a <_p abdd$, $ab <_p abcd$, $ab <_p abdd$, $cd <_p cdab$

$a <_p ab <_p abcd$
 $<_p abdd$ et $cd <_p cdab$

- Ordre lexicographiques :

$a <_l ab <_l abcd <_l abdd <_l bc <_l cd <_l cdab <_l dbc$

- Ordre hiérarchique :

$a <_h ab <_h bc <_h cd <_h dbc <_h abcd <_h abdd <_h cdab$

Langage

Définition 1.15 - Langage

Un **langage** L sur un alphabet A est un ensemble de chaînes (ou ensemble de mots) sur A . L est donc un sous-ensemble de A^* , autrement dit $L \subseteq A^*$.

L'ensemble des langages L sur A est l'ensemble $\mathcal{P}(A^*)$ des parties de A^* , autrement dit : $L \in \mathcal{P}(A^*)$.

Étant donné un alphabet A , parmi tous les langages L de $\mathcal{P}(A^*)$:

- Le **langage neutre** est celui dont le seul mot est la chaîne vide : $\{\varepsilon\}$
- Le **langage vide** est celui qui ne contient aucun mot : \emptyset
- Un **langage fini** est un langage qui contient un nombre fini de mots
- Un **langage infini** est un langage qui n'est pas fini
- **Langage préfixe/suffixe** : un langage L est dit posséder la propriété préfixe (resp. suffixe) si aucune chaîne de L n'est préfixe (resp. suffixe) propre d'une autre chaîne de L

Opérateurs ensemblistes classiques et opérateurs induits par la concaténation des mots

Définition 1.16 - Union, intersection, différence, complémentaire

Union : $\mathbf{L} \cup \mathbf{M} = \{x \mid x \in L \text{ ou } x \in M\}$

Intersection : $\mathbf{L} \cap \mathbf{M} = \{x \mid x \in L \text{ et } x \in M\}$

Différence (ou exclusion) : $\mathbf{L} \setminus \mathbf{M} = L - M = \{x \mid x \in L \text{ et } x \notin M\}$

Complémentaire sur A^* : $\mathbf{Comp}(\mathbf{L}) = A^* \setminus L = \{x \mid x \in A^* \text{ et } x \notin L\}$

Définition 1.17 - Opérateurs induits par la concaténation des mots

Produit : $\mathbf{LM} = \mathbf{L} \times \mathbf{M} = \{x \cdot y \mid x \in L \text{ et } y \in M\}$

Puissance : $\mathbf{L}^0 = \{\varepsilon\}$ et $\mathbf{L}^n = L \times L^{n-1} = L^{n-1} \times L$

Fermeture de Kleene : $\mathbf{L}^* = \bigcup_{i=0 \dots \infty} L^i$

Fermeture positive : $\mathbf{L}^+ = \bigcup_{i=1 \dots \infty} L^i$

Propriétés des opérateurs entre langages

- Le langage vide est **absorbant** pour la concaténation des langages :
 $\emptyset \times L = \emptyset = \emptyset \times L$
- $\langle \mathcal{P}(A^*), \times, \{\varepsilon\} \rangle$ est un **monoïde** :
 - Le langage neutre est élément neutre pour la concaténation des langages : $\{\varepsilon\} \times L = L = L \times \{\varepsilon\}$
 - La concaténation des langages est **associative** : $(L1 \times L2) \times L3 = L1 \times (L2 \times L3)$
- $L^+ = L \times L^* = L^* \times L$ et $L^* = \{\varepsilon\} \cup L^+$
- $\emptyset^* = \{\varepsilon\}$ et $\{\varepsilon\}^* = \{\varepsilon\}$

Exercice sur les langages et opérations

Montrer que le produit de deux langages préfixes est un langage préfixe

Exercice sur les langages et opérations - Démonstration

Montrer que le produit de deux langages préfixes est un langage préfixe

Démonstration : **par l'absurde**, assez simple en utilisant le **lemme de Levi**

- Soient L et M deux langages préfixes, $w_1, w_2 \in LM$
- **Démonstration par l'absurde** : supposons que w_1 est préfixe propre de $w_2 \Rightarrow \exists z$ tel que $w_1 \cdot z = w_2$
- De plus, $\exists u_1, u_2 \in L$ et $\exists v_1, v_2 \in M$ tels que $w_1 = u_1 \cdot v_1$ et $w_2 = u_2 \cdot v_2$
- **Lemme de Levi** sur $u_1 \cdot (v_1 \cdot z) = u_2 \cdot v_2$
 $\Rightarrow \exists! z$ tel que $(u_1 = u_2 \cdot w$ et $v_2 = w \cdot v_1 \cdot z)$ ou $(u_2 = u_1 \cdot w$ et $v_1 = w \cdot v_2 \cdot z)$
- Or u_1 n'est pas préfixe de u_2 et réciproquement $\Rightarrow u_1 = u_2$ et $w = \varepsilon \Rightarrow v_2 = v_1 \cdot z$ ou $v_1 = v_2 \cdot z$
- **Contradiction** car v_1 n'est pas préfixe de v_2 et réciproquement
- **La supposition n'est pas vraie** : w_1 n'est pas préfixe propre de w_2
- De même w_2 ne peut pas être préfixe propre de $w_1 \Rightarrow LM$ est un langage préfixe